

**АЛЬФА
БУДУЩЕЕ**

Альфа Банк

Магистратура Альфа-Банка и МФТИ

RAG-ответы по базе знаний

Аннотация



Создайте интеллектуальный pipeline RAG-системы, который по пользовательскому запросу находит наиболее релевантные фрагменты в корпусе данных и на их основе формирует связанный, корректный и полезный ответ с помощью генеративного модуля.



Постановка задачи



Разработайте полноценный pipeline RAG-системы, которая по входному пользовательскому вопросу находит релевантные фрагменты в предоставленном корпусе данных и формирует на их основе качественный ответ. Для этого:

01

Изучите структуру предоставленного корпуса текстовых данных, включающего вопросы пользователей и распарсенные подстраницы сайта alfabank.ru.

02

Постройте retrieval-пайплайн, который для каждого входного вопроса возвращает top-k наиболее релевантных документов или фрагментов корпуса.

03

Разработайте подмодуль, который возвращает ответ на вопрос пользователя, сгенерированный с учетом информации в подобранных фрагментах корпуса.

04

Сформируйте итоговый pipeline, включающий последовательные этапы: retrieval → grounding → generation.


05

Сохраните результат генерации в формате CSV и отправьте решение на платформу.

Для проверки соответствия решения условиям и ограничениям хакатона топ-10 решений по итогам оценки будут дополнительно проходить code review.

ВАЖНО!

Вы имеете право загружать ваше предсказание на платформу в формате CSV не более 3 раз в течение одного дня (в промежутке между 00:00 и 23:59 по МСК).



Бизнес-контекст



Вопросно-ответные (Q&A) системы — это прикладные ИИ-сервисы, которые принимают текстовый вопрос и возвращают точный, краткий ответ. В классическом варианте есть два подхода: экстрактивный (фраза-ответ берется из источника) и абстрактивный (ответ генерируется моделью по доступной в ее базе информации). Главные требования к Q&A: точность, опора на источники (evidence), контроль галлюцинаций и понятная трассируемость, возможность проследить, откуда взялся факт.

[RAG \(Retrieval-Augmented Generation\)](#) — это архитектура, которая решает проблему «галлюцинаций» и устаревших знаний у языковых моделей. Сначала retriever — часть пайплайна, которая отвечает за поиск и экстракцию нужного фрагмента текста, — находит релевантные фрагменты в вашей базе знаний. Затем generator — языковая модель — формирует ответ, опираясь именно на эти фрагменты. Тем самым знания подгружаются динамически: вы обновляете корпус — и система отвечает по новым данным без дообучения самой модели.

КАК ЭТО РАБОТАЕТ ПО ШАГАМ:

Индексирование.

Текстовые данные разбиваются на чанки (chunks), для каждого чанка рассчитываются эмбединги, после чего строится векторный индекс для эффективного поиска.

Извлечение.

Для запроса генерируются эмбединги, и на основе этого выполняется поиск в индексе, возвращая топ-k ближайших чанков. Для повышения точности результатов часто используется переранжировка с применением cross-encoder.

Промптование.

Отобранные текстовые фрагменты передаются в модель с инструкцией: «Используй только данные из контекста, ссылайся на источники. Если информация не найдена, сообщи, что данных нет».

Генерация.

Языковая модель формирует ответ, сохраняя необходимый стиль, длину и ссылки. Также могут быть добавлены верификаторы, такие как self-check, answerability, и цитирование для повышения достоверности ответа.


Бизнес-контекст



Большая языковая модель в этой архитектуре появляется только на финальном этапе, так как выступает не источником знаний, а обобщает и связно излагает релевантный контекст, выделяет факты, корректирует неоднозначность формулировок и выдает финальный ответ. Большая часть качества идет не из огромной модели, а из инженерии пайплайна: размер чанков, нормализация и очистка разметки, метрики близости эмбедингов и параметры поиска, реранжировка, промптинг инструкции, настройка фильтров токсичности.

RAG-системы активно реализуются в чат-ботах, в том числе в банковских приложениях, улучшая качество генерируемого ответа. Так, Альфа-Банк начал использовать [ИИ для помощи в выборе дебетовых карт](#). В 2023 году в Альфа-Банке началась разработка ИИ-платформы, позволяющей ускорить выполнение рутинных задач сотрудников, [AlfaGen](#), объединяющей несколько погруженных в кон-

текст работы в Альфа-Банке благодаря методу RAG языковых моделей. ИИ-агенты на базе RAG позволяют не только успешно генерировать ответы на вопросы и искать информацию по базе знаний. Команде системных аналитиков в Альфа-Банке удалось настроить агента на [проверку технической документации](#) в «Альфа-Онлайне».



Бизнес-контекст



КРИТЕРИИ УСПЕХА

- 01 Система формирует осмысленные и полезные ответы, корректно отвечающие на пользовательский запрос.
- 02 Ответы опираются на извлеченные фрагменты корпуса, минимизируя галлюцинации и неподтвержденные факты.
- 03 Генеративный модуль интегрирован с retrieval-pipeline и использует единый формат данных на стыке модулей.
- 04 Система корректно обрабатывает случаи отсутствия релевантной информации.

ОГРАНИЧЕНИЯ

Для создания и настройки модели вы можете использовать язык Python версии 3.10 и выше. Также вы можете использовать любую библиотеку для машинного обучения и предобработки данных, являющуюся OpenSource-ресурсом. Использование закрытых библиотек, частных API и чужого кода, не подпадающего под разрешение о свободном распространении и использовании, запрещено.

Вызовы внешних закрытых API генерации не допускаются, inference выполняется локально.

Корпус данных фиксирован организаторами, использование дополнительных закрытых данных не допускается.

Ответы системы не должны содержать конфиденциальную информацию и заведомо некорректные или опасные рекомендации.



Бизнес-контекст



ИСТОЧНИКИ ИНФОРМАЦИИ

[\(Ссылка на данные\)](#)

Вам предоставляется расширенный набор данных, состоящий из таблиц формата .csv:

01 **questions.csv** – база пользовательских запросов, для которых необходимо выстроить retrieval и генерацию ответа. Содержит следующие поля:

- **q_id** – уникальный идентификатор вопроса;
- **query** – формулировка пользовательского запроса.

02 **websites.csv** – корпус знаний, использующийся в retrieval-части пайплайна. Содержит:

- **web_id** – уникальный идентификатор веб-страницы;
- **website** – URL источника;
- **web** – заранее извлеченный текст с веб-страницы.


Файл **sample_submission.csv** – пример файла решения для загрузки на платформу

ПРОСТРАНСТВО РЕШЕНИЙ

Вы имеете право использовать любые модели из открытых (Open Source) библиотек и репозиториев при построении любого компонента пайплайна (retrieval, reranking, генерации, сжатия контекста и др.). Выбор архитектуры, размера модели, метода оптимизации и способа инференса не ограничивается организаторами.

При этом в решении допускаются только те модели, которые:

- имеют открытую, свободно используемую лицензию;
- не требуют обращения к закрытым внешним API, облачным сервисам или проприетарным коммерческим LLM.



О компании



Альфа-Банк — крупнейший универсальный частный банк в России. На протяжении 30 лет занимает ведущие позиции во всех сегментах банковского бизнеса.

О БАНКЕ В ЦИФРАХ

210 млрд рублей
чистая прибыль¹

40 млн
клиентская база
физических лиц

2 млн
корпоративных клиентов
(компаний малого и среднего
бизнеса)

800+
офисов в 28 регионах
присутствия

400+
продуктовых команд

800+
проектов в год

3-е место
в рейтинге российских банков
по объемам кредитования
физических лиц



АЛЬФА-БАНК — ПОБЕДИТЕЛЬ СЛЕДУЮЩИХ ПРЕМИЙ:

- Топ-1 работодатель по версии [HeadHunter](#), [Changellenge >>](#), [FutureToday](#)
- [Лучший мобильный банк](#) в браузере смартфона по версии Markswebb
- [Лучший сервис](#) для премиальных клиентов по версии Frank RG
- Alfa Digital — [лучший IT-бренд](#) работодателя в бигтехе в 2025 году по рейтингу IT-брендов работодателей от консалтинговой компании «ЭКОПСИ» и платформы «Хабр»
- Первым в стране получил статус [«Работодатель нового поколения»](#) как самый технологичный банк по результатам исследования Changellenge >> Best Company Award в 2025 и 2026

¹ Чистая прибыль банка по итогам 2024 года на основе международных стандартов финансовой отчетности (МСФО).

Приложение

МЕТРИКА BERT-RECALL

Метрика Recall-L оценивает качество текстового ответа в задачах вопрос-ответ и генерации. Она показывает, какую долю содержательной релевантной информации из эталонного ответа система смогла воспроизвести, одновременно вводя мягкий штраф за чрезмерную длину ответа. В основе лежит компонент recall метрики BERTScore, то есть мы измеряем полноту не по точным совпадениям слов, а по семантическому совпадению в пространстве эмбедингов трансформера.

Пусть для вопроса g_q задан эталонный ответ g_q и сгенерированный ответ a_q . Обозначим через $R_{\text{BERT}}(q)$ значение **recall** метрики BERTScore для пары $(a_q)(g_q)$. Через l_r обозначим длину эталонного ответа в токенах, через l_a – длину ответа участника. Тогда коэффициент длины $L(q)$ задается так:

$$L(q) = \begin{cases} 1, & l_a \leq 1.5 l_r, \\ -\frac{2}{3} \frac{l_a}{l_r} + 2, & 1.5 l_r < l_a < 3 l_r, \\ 0, & l_a \geq 3 l_r. \end{cases}$$


То есть ответы длиной до 1.5 от эталона не штрафуются, затем значение коэффициента линейно убывает до нуля к моменту, когда ответ в три раза длиннее эталонного, и все ответы длиннее чем $3l_r$ получают нулевой множитель по длине. Итоговая метрика для запроса q равна

$$\text{Recall } L(q) = R_{\text{BERT}}(q) * L(q).$$

Общее значение по набору вопросов Q :

$$\text{RecallL} = \frac{1}{|Q|} \sum_{q \in Q} \text{Recall } L(q)$$

Интерпретация: значение $\text{Recall-L} = 0.78$ означает, что в среднем ответы покрывают около 78 % релевантного содержимого эталона с точки зрения **BERTScore-recall** и при этом не чрезмерно раздуваются по длине; диапазон метрики — от 0 до 1, где результаты, максимально приближенные к 1, считаются лучшими.



CHANGELLENGE >>

Кейс написан и опубликован
Changellenge >> —
ведущей организацией
по кейсам в России.

www.changellenge.com

Альфа Банк

Кейс создан совместно
с АО «Альфа-Банк»

www.alfabank.ru

